

Сервис корпоративного обучения по аналитике

Проект по Наукам о данных
Антон Лебедев



Идея стартапа

Платформа корпоративного обучения аналитиков, доступная компаниям по подписке




Создаем B2B сервис, на котором предлагаем курсы по аналитике, который компании могут приобрести по подписке для обучения своих сотрудников

Необходимость навыка

Оцениваем, насколько навык необходим компаниям, нанимающих аналитиков

Парсинг вакансий с hh.ru



Дефицит курсов по навыку

Оцениваем, покрыт ли уже спрос на курсы по этим навыкам на онлайн-платформах

Парсинг курсов со Степика

Пайплайн анализа навыков в вакансиях

Используем асинхронный динамический парсинг через Playwright

1 Сбор ссылок

Находим 100 страничек по запросу “Аналитик” и с каждой из них собираем ссылки на вакансии в общий список

2 Парсинг вакансий

Выделяем 5 воркеров и даем каждому из них $\frac{1}{5}$ ссылок. Далее каждый воркер проходит по своему списку и парсит детали вакансии

3 Сбор в датафрейм

Из списка словарей собираем данные в датафрейм с информацией о названии вакансии, ее описанию, зарплате, опыту, графику и т.д.

4 Предобработка з/п

Зарплата может встречаться в множестве разных форматов (“от 30000 руб.”, “50000 тенге”). Я преобразую их к единому виду, извлекая 2 признака: `salary_from` (мин. з/п) и `salary_to` (макс. з/п)

5 Список навыков




Я создаю список (дерево) из навыков, которые в дальнейшем буду извлекать, с помощью анализа наиболее популярных n-грам из описания вакансии

6 Извлечение навыков

Извлекаю из каждого описания вакансии навыки, определенные на прошлом этапе, с помощью регулярных выражений. При этом если есть какой-то поднавык (Pandas), то я добавляю и навык (Python)



Описательная статистика

Распределение опыта, зарплаты и типов аналитики



Популярность навыков


Базы данных и SQL наиболее популярны у работодателей



Популярность навыков в разрезе опыта

Популярность навыков разнится в зависимости от опыта кандидата

20 самых часто встречающихся навыков с разбивкой по опыту




Выводы:

1. На позициях без опыта Excel важнее, чем SQL, в отличие от позиций с опытом
2. На вакансиях без опыта редко спрашивают BPMN и UML, а на вакансиях с опытом 3-6 лет они очень актуальны
3. Python наиболее популярен на вакансиях с опытом 1-3 года


Популярность навыков в разрезе типа аналитики

Для разных направлений аналитики нужен разный технологический стек

Наиболее необходимые навыки для бизнес-аналитика




Наиболее необходимые навыки для системного аналитика




Стеки технологий для различных типов:

- **Системный аналитик** - SQL, BPMN, UML, REST, Confluence, Jira, SOAP
- **Аналитик данных** - SQL, Excel, Python, Power BI, сводные таблицы
- **Бизнес-аналитик** - BPMN, SQL, Excel, UML, Jira, 1C
- **BI-аналитик** - Power BI, SQL, Excel, Python
- **1С-аналитик** - 1C
- **Продуктовый аналитик** - Sql, Python, Power BI, Excel

Наиболее необходимые навыки для продуктового аналитика



Наиболее необходимые навыки для дата-аналитика



Пайплайн анализа курсов по навыкам

У Степика есть свой API, который я и использую для статического парсинга

1 Поиск курсов

Для каждого навыка, определенного в первой части, я строю поисковой запрос и извлекаю курсы по этому запросу вплоть до 4 страницы поиска. Если один курс встречается в 2 запросах, то я НЕ добавляю его заново в датафрейм

2 Парсинг данных курса

Для каждого курса я из JSON извлекаю его параметры: кол-во слушателей, описание, цена и добавляю их в словарь

3 Парсинг отзывов


На Степике данные об отзывах на отдельной странице, поэтому я также прохожусь по всем таким страницам и собираю из них информацию о средней оценке и кол-ве отзывов

4 Добавление навыков

Далее я прохожусь по описанию курса с помощью уже написанных регулярных выражений и добавляю те навыки, которые еще не добавлены туда в ходе поисковых запросов

20 наиболее популярных курсов


Курсы про Python и Github наиболее представлены в топ-20



Плата за курс и кол-во слушателей

Наличие платы за курс снижает количество слушателей - и разница статистически значима


Кол-во слушателей курса в зависимости от наличия платы (логарифмическая шкала)



Также провел тест Манна-Уитни на сравнение среднего между 2 группами: $p\text{-value} < 0.01$, поэтому бесплатные курсы имеют **статистически значимо** больше слушателей, чем платные

Кол-во изучающих каждый навык

Python, математическая статистика, Hadoop и SQL лидируют



Дэшборд

Можно выбрать метрику, по которой отсортировать навыки, кол-во навыков и получить бар-чарт с навыками

Анализ курсов Степика по навыкам

Фильтры

Метрика для бар-чарта


Слушатели (сумма)

Топ N навыков

5 10 15 20 25 30 30

Топ навыков

Топ 30 навыков — Слушатели (сумма)



Выводы для стартапа

Создаем курсы с наибольшей необходимостью и наименьшей удовлетворенностью спроса

1

BPMN и UML

Являются важным инструментом для работодателей, в особенности на позициях с опытом и для бизнес-аналитиков, в то время как курсов про них на Степике очень мало

2

Confluence

Входит в топ-10 самых популярных навыков среди работодателей и опережает Jira, но не входит даже в топ-20 самых изучаемых навыков на Stepik

3


SOAP

Аналогично занимает высокие позиции в рейтинге работодателей, но не входит в топ-20 самых изучаемых навыков на Stepik

4

OpenAPI

Актуальный навык для вакансий с опытом в 3-6 лет, но с малым количеством курсов на Степике



Спасибо за внимание!